

Прогноз потребительских расходов муниципалитетов и ранние сигналы сдвигов

Отчёт построен автоматически из результатов запуска `municipal_20261004T140239Z`. Данные: СберИндекс, безналичные расходы на жителя по 12 096 рядам (2016 МО × 6 категорий), январь 2023 – декабрь 2024. Численные утверждения ниже прочитаны из файлов результатов. Каталог обученных моделей и все метрики: `docs/MODELS_AND_METRICS_RU.md`.

Резюме

- **Прогнозы 1/3/6/12 мес.** Ансамбль на тесте имеет MAE 440/514/466/583 руб. против 640/719/736/1093 у Prophet, то есть на 31/28/37/47% меньше. Выбор моделей и весов заморожен до открытия теста.
- **Откуда выигрыш.** Основной вклад — национальные ряды с 2018 г.: у МО всего 24 месяца, поэтому сезонность и рост берутся из страны, а по МО оценивается уровень и небольшая поправка. Абляция показывает вклад в явном виде.
- **Фундаментальные модели** (Chronos-Bolt, Chronos-2, Chronos-2 с национальной ковариатой, TimesFM на подвыборке) без дообучения на таких коротких рядах уступают Prophet на горизонтах ≥ 3 (на $h=1$ Chronos-2 с ковариатой лучше) и получили нулевой вес в ансамбле.
- **Детекторы CUSUM / Page-Hinkley / BOCPD** сравнены тремя способами и на недельных реальных рядах; победитель зависит от способа разметки. **Раннее предупреждение: навык не подтверждён.**
- **Новости** как датированные официальные события (ставка ЦБ, реестр) не показали пользы относительно плацебо.
- **Недельный nowcast** национального уровня с поправкой смещения лучше $h=1$ -ансамбля при ≥ 2 неделях месяца; без поправки он непригоден.
- Прогноз на 2025 г. по МО заморожен для будущей проверки.

1. Данные

Источник	Что	Период	Использование
СберИндекс, <code>consumption.parquet</code>	безналичные расходы на жителя, руб./мес., 6 категорий	2023-01...2024-12	цель; 12096 полных рядов, 1044 неполных исключены
Справочник МО (<code>t_dict_municipal</code>)	регион, тип, координаты, интервалы действия	срез 2024	статические признаки, сопоставление событий
<code>market_access.parquet</code>	индекс доступности рынков	2024	статический признак (log)
Национальные расходы СберИндекса	5 категорий, млрд руб./мес.	2018-12...2026-08	приор: сезонность и рост только по данным $\leq$ origin
Недельный рост r/g (46 категорий), активность	недельные ряды	2021/2023...2026-09	детекторы, nowcast
ЦБ РФ: ключевая ставка	по дням	2018...2026	новостные/макро-признаки
Реестр событий	7 событий со ссылками	2023–2024	событийная оценка детекторов

Лицензия данных СберИндекса — CC BY-SA 4.0. Муниципальные файлы в репозиторий не включены (`scripts/get_data.sh` скачивает их в `data/raw/`); небольшие национальные и недельные выгрузки лежат в корне проекта.

2. Протокол оценки

Правила организатора мне неизвестны, поэтому использован «конкурсный» протокол, описанный в открытых работах участников: validation — цели янв.-июнь 2024, test — цели июль–декабрь 2024, расширяющееся окно, прогноз горизонтов 1/3/6/12 из каждого origin с историей не менее 6 месяцев. **Допущение подлежит сверке с официальными правилами.**

1. Для каждого origin и каждого ряда используются только значения $\leq$ origin; direct-метки обучения — только с целью $\leq$ origin (проверено тестами `tests/test_municipal.py`: изменение будущих значений не меняет признаки, метки и

- национальные приоры).
2. Конфигурация структурной модели и веса ансамбля выбраны **no validation**; `frozen_selection.json` записан до подсчёта метрик теста. После первого показа теста модели, кандидаты и веса не менялись; изменения касались только расчёта Prophet для origin 12.2024 (нужен для прогноза 2025, на тест не влияет) и оформления. Значительная часть решений (дрейф без экстраполяции за обученный горизонт, сжатие 0.25) принята по validation после того, как первая версия модели провалилась на h=6.
 3. Метрика — MAE в рублях на жителя по всей сетке (сетки у всех моделей совпадают, покрытие 100%), дополнительно R² по уровню и по изменению.
 4. Неопределённость — парный bootstrap по МО (1000 повторов) и по целевым месяцам (6 месяцев).
 5. Допущения: значение месяца origin известно на origin; актуальная версия данных (без пересмотров); validation для h=12 содержит один целевой месяц (2024-06).

3. Модели

- **Baseline'ы:** LastValue; SeasonalNaive (то же значение год назад, а если нет — LastValue); **Prophet** (месячные даты, настройки по умолчанию, годовая сезонность `auto` включается только при истории >2 лет; настройки организатора неизвестны).
- **Национальный путь (NatPath):** прогноз = локальный уровень (среднее по последним 3 месяцам, скорректированное на реализованное национальное изменение) × национальное SeasonalGrowth-изменение от origin до цели (сезонность и темп роста из национальных рядов; соответствие муниципальных категорий национальным задано заранее).
- **SeasonalNaive_NatGrowth:** значение того же месяца год назад × национальный годовой рост.
- **StructHGB:** градиентный бустинг (MAE) по остатку относительно NatPath: признаки — локальные импульсы относительно страны, шум, сезонные разности, региональные и категорийные средние, статические признаки МО. Дрейф на месяц умножается на горизонт, **но не дальше обученного** ($h \leq origin-5$) и сжимается на валидации (коэффициент 0.25).
- **Foundation:** Chronos-Bolt-small, Chronos-2 (zero-shot), Chronos-2 + национальный путь как ковариата, TimesFM-2.5 (подвыборка). Ревизии чекпойнтов в `artifacts/municipal_runs/_foundation/*_meta.json`.
- **Ансамбль:** веса минимизируют MAE на validation (линейная программа, симплекс), отдельно по горизонтам.
- **Интервалы:** split-conformal по относительной ошибке на validation, по (горизонту, категории).

4. Прогноз 1/3/6/12 мес.

Главный результат. На независимом тесте (цели июль–декабрь 2024, 12 096 рядов) замороженный ансамбль имеет MAE **440 / 514 / 466 / 583 руб. на жителя** для горизонтов 1 / 3 / 6 / 12 мес. против **640 / 719 / 736 / 1093** у Prophet. Снижение — **31% / 28% / 37% / 47%**. Парный bootstrap по МО (1000 повторов) даёт 95% интервалы разности MAE строго ниже нуля на всех горизонтах; bootstrap по шести целевым месяцам (общий шок месяца не усредняется по МО) также исключает ноль на всех горизонтах. R² по изменению относительно origin (динамика, а не масштаб МО): ансамбль 0.67 / 0.74 / 0.84 / 0.69, Prophet 0.13 / 0.42 / 0.53 / -0.44. Обычный R² по уровню 0.97–0.996 у всех моделей и почти ничего не показывает: уровень определяется масштабом МО.

Таблица теста

Модель	MAE h=1	MAE h=3	MAE h=6	MAE h=12	Среднее	Δ к Prophet, % (среднее)
Ensemble	439.6	513.9	466.1	583.4	500.7	37.2
SeasonalNaive_NatGrowth	546.7	542.6	529.0	612.4	557.7	30.0
NatPath_K1	402.8	724.3	873.2	612.4	653.2	18.1
StructHGB	499.9	736.4	883.1	606.2	681.4	14.5

Модель	MAE h=1	MAE h=3	MAE h=6	MAE h=12	Среднее	Δ к Prophet, % (среднее)
NatPath_K3	525.6	757.9	757.1	686.5	681.8	14.5
Prophet	640.4	718.6	736.5	1092.8	797.1	0.0
LocalOnlyHGB	665.9	774.7	930.3	1165.1	884.0	-10.9
Chronos2_NatCov	506.2	721.8	969.8	1533.3	932.8	-17.0
LastValue	624.4	863.8	1124.2	1288.6	975.3	-22.4
LocalBase_K3	691.0	815.6	1005.7	1534.5	1011.7	-26.9
Chronos2	612.9	877.1	1360.7	1817.0	1166.9	-46.4
SeasonalNaive	1288.6	1288.6	1288.6	1288.6	1288.6	-61.7
ChronosBolt	706.7	1024.2	1603.4	1986.0	1330.1	-66.9

Что даёт национальная информация (абляция)

Вариант	MAE h=1	MAE h=3	MAE h=6	MAE h=12
Локальный уровень (без национальных данных)	691.0	815.6	1005.7	1534.5
+ GBM без национальных данных	665.9	774.7	930.3	1165.1
Национальный путь (NatPath_K3)	525.6	757.9	757.1	686.5
NatPath + остаточный GBM (StructHGB)	499.9	736.4	883.1	606.2

Национальный путь (сезонность и темп роста из рядов с 2018 г., только по данным до origin) снижает среднюю MAE с 1012 до 682 (33%). Остаточный GBM поверх национального пути даёт смешанный эффект: лучше на h=1 (526 → 500) и h=12 (687 → 606), но хуже на h=3 и h=6; в среднем 682 → 681. Основной вклад вносит национальный приор, а не нелинейная модель по МО. Причина: у МО всего 6–23 месяца истории, и ни сезонность, ни годовой рост по такому ряду оценить нельзя.

Веса ансамбля (подобраны на validation)

Модель	1	3	6	12
Prophet	0.25	0.47	0.27	0.28
SeasonalNaive_NatGrowth	0.35	0.41	0.66	0.64
StructHGB	0.40	0.12	0.06	0.07

Веса найдены линейной программой (минимум MAE на симплексе); для h=12 использованы пары h=6 и h=12, потому что на validation у h=12 один целевой месяц. Foundation-модели получили нулевой вес: на validation они не лучше выбранных кандидатов.

По категориям (среднее по 4 горизонтам)

Категория	Ensemble	Prophet	Δ, %
Все категории	1236.3	2319.8	46.7
Здоровье	137.6	201.0	31.5
Маркетплейсы	710.7	649.0	-9.5
Общественное питание	132.7	225.8	41.2
Продовольствие	652.1	1138.5	42.7
Транспорт	135.0	248.3	45.6

В категории «Маркетплейсы» с очень быстрым ростом и сильной сезонностью ансамбль не лучше Prophet — это слабое место, которое стоит исправлять отдельным национальным приором для маркетплейсов.

По размеру ряда (тертили уровня внутри категории)

Терциль	Ensemble	Prophet	Δ, %
T1	446.9	626.0	28.6
T2	461.7	706.8	34.7
T3	593.6	1058.6	43.9

Интервалы

Горизонт, мес.	Номинал	Покрытие на тесте	Средняя полуширина (отн.)
1.000	0.900	0.889	0.166
3.000	0.900	0.874	0.193
6.000	0.900	0.941	0.274
12.000	0.900	0.944	0.417

Интервалы split-conformal по относительной ошибке на validation, отдельно для горизонта и категории. На тесте покрытие близко к номиналу 0.9.

Фундаментальные модели (zero-shot)


Модель	MAE h=1	MAE h=3	MAE h=6	MAE h=12
Chronos2	612.9	877.1	1360.7	1817.0
Chronos2_NatCov	506.2	721.8	969.8	1533.3
ChronosBolt	706.7	1024.2	1603.4	1986.0
Prophet	640.4	718.6	736.5	1092.8

Chronos-Bolt-small и Chronos-2 использованы без дообучения, контекст — `history[:origin+1]`. Версия `Chronos2_NatCov` получает национальный путь как known-future ковариату. Результат: на коротких рядах (6–23 точки) zero-shot модели уступают Prophet на $h \geq 3$; на $h=1$ Chronos-2 и особенно Chronos-2 с ковариатой чуть лучше Prophet. Ковариата заметно улучшает Chronos-2 на всех горизонтах, но не доводит его до Prophet на $h \geq 6$. Возможное пересечение обучающих корпусов чекпойнтов с 2023–2024 гг. проверить нельзя, поэтому это оценка современной модели, а не исторического deployment.

TimesFM-2.5 (200M) на CPU считает ~0,13 с на ряд, поэтому оценён на случайной подвыборке из 200 МО (1200 рядов, все категории; seed 42), остальные модели сравнены на тех же рядах:


Модель	1	3	6	12	среднее
Ensemble	427.7	498.0	450.3	583.4	489.8
SeasonalNaive_NatGrowth	533.3	527.0	510.1	590.9	540.3
NatPath_K3	506.1	723.2	720.0	672.2	655.4
Prophet	622.1	694.8	709.2	1077.6	775.9
Chronos2_NatCov	497.1	703.4	946.1	1494.1	910.2
LastValue	610.4	844.1	1094.5	1234.1	945.8
TimesFM	549.3	785.8	1245.0	1630.3	1052.6
Chronos2	603.5	869.3	1327.6	1757.5	1139.5

Тест (июль-декабрь 2024): MAE по горизонтам, 12 096 рядов




MAE по горизонтам на тесте


Выигрыш у Prophet (95% bootstrap по MO)



Снижение MAE относительно Prophet с 95% bootstrap по MO



Веса ансамбля



MAE по категориям и размеру ряда



Карта выигрыша у Prophet по МО (категория «Все категории»)

5. Структурные изменения: обнаружение и предупреждение

Детекторы CUSUM, Page-Hinkley и BOCPD подаются стандартизированными остатками прогноза $h=1$, выпущенного до наблюдения (национальный путь $\times$ локальный уровень). Масштаб остатка считается только по прошлому и сжимается к масштабу категории. Пороги подобраны на месяцах 10–17 при бюджете **1 ложная тревога на 100 ряд-месяцев**, оценка — на месяцах 18–23. Реальных размеченных шоков по МО у нас нет, поэтому оценка идёт тремя независимыми способами, и ни один из них не называется «истиной».

А. Инъекция известных сдвигов в реальные остатки

Сдвиг $\pm 1.5/2.5/4\sigma$ добавляется в 5% рядов (604 события) на месяцы 18–20; остальные 95% остаются реальными и служат фоном для ложных тревог. Пять независимых повторов.

Метод	Порог	Precision	Recall	F1	$\pm$ F1 (5 повторов)	Медиана задержки, мес.	Ложных тревог / 100 ряд-мес.
CUSUM	10.000	0.161	0.449	0.237	0.004	1.400	1.914
PageHinkley	12.000	0.090	0.314	0.140	0.004	1.200	2.716
BOCPD	0.500	0.128	0.353	0.188	0.009	1.000	2.097

Метод	Recall при сдвиге 1.5σ	Recall при сдвиге 2.5σ	Recall при сдвиге 4.0σ
CUSUM	0.22	0.37	0.74
PageHinkley	0.15	0.23	0.54
BOCPD	0.20	0.34	0.51

Частота тревог на тесте выше, чем на калибровке (~2 против ≤1 на 100 ряд-месяцев): в тесте часть тревог — настоящие шоки или сезонные промахи прогноза (Дек–Янв), а не ложные. Поэтому precision здесь консервативна.

B. Реестр датированных событий

В реестре 7 событий (паводки, теракты, обстрелы; ссылки в `data/external/event_registry.csv`). Сопоставление с МО по названию внутри региона нашло 6 территорий. Белгорода, Курска и Суджи в панели нет (не прошли порог качества СберИндекса), а для Севастополя, Дербента и Махачкалы сопоставление по названию МО не нашло. Оценимы Орск, Оренбург, Новотроицк (паводок, 04.2024) и Красногорск («Крокус», 03.2024).

event_id	pattern	method	рядов	доля_с_тревогой	макс_z	фон_все_ряды
EV01	Новотроицк	BOCPD	6	0.17	2.84	0.07
EV01	Новотроицк	CUSUM	6	0.00	2.84	0.09
EV01	Новотроицк	PageHinkley	6	0.00	2.84	0.02
EV01	Оренбург	BOCPD	6	0.00	2.74	0.07
EV01	Оренбург	CUSUM	6	0.00	2.74	0.09
EV01	Оренбург	PageHinkley	6	0.00	2.74	0.02
EV01	Орск	BOCPD	6	0.17	3.43	0.07
EV01	Орск	CUSUM	6	0.00	3.43	0.09
EV01	Орск	PageHinkley	6	0.00	3.43	0.02
EV05	Красногорск	BOCPD	6	0.00	2.80	0.07
EV05	Красногорск	CUSUM	6	0.00	2.80	0.06
EV05	Красногорск	PageHinkley	6	0.00	2.80	0.01

Отклик на реальные события слабый: максимум |z| 2.7–3.4σ, тревоги единичны (BOCPD по 1 из 6 категорий в Орске и Новотроицке), в других случаях — нет. Это не доказывает отсутствие эффекта — месячная сумма по всем категориям сглаживает локальный шок, — но и не подтверждает работоспособность детекторов на реальных событиях.

C. Offline-сегментация как проху-разметка

F1 по меткам offline-сегментации z-рядов (3000 случайных рядов, тест). Разметка не независима от формы z и не равна истине, поэтому это анализ чувствительности: ранжирование методов зависит от типа разметки (на инъекциях выигрывает CUSUM, на offline-метках — BOCPD).

Штраф	BOCPD	CUSUM	PageHinkley
2.000	0.608	0.016	0.220
4.000	0.523	0.019	0.183
8.000	0.359	0.010	0.209

D. Недельные реальные ряды (46 категорий, 151 неделя)

У недельных рядов достаточно длины для оценки на реальных данных: пороги — на первых 55% недель при бюджете 1/100, оценка — на последних 30%. Метки — offline-сегментация со штрафом 16 (чувствительность по штрафам 4/8/16/32 — в `artifacts/weekly_shocks/detector_metrics_proxy_labels.csv`).


method	threshold	n_proxy_events_test	n_alarms_test	event_precision	event_recall	event_f1	false_alarms_per_100_series_weeks	median_delay_weeks
CUSUM	20.000	58	26	0.500	0.224	0.310	0.614	4.000
PageHinkley	24.000	58	34	0.529	0.310	0.391	0.756	3.000
BOCPD	0.900	58	14	0.357	0.086	0.139	0.425	1.000

Е. Раннее предупреждение (вероятность сдвига в окне (t, t+k])

Признаки на момент t: z, средние и максимумы |z| за 4 недели, доля рядов с |z|>2 (ширина шока), оценки трёх детекторов, изменение ключевой ставки ЦБ за 13 недель и недели с последнего изменения. Обучение — на метках, зрелых к границе; между train и test зазор 8 недель.


Окно, нед.	Модель	Доля событий (базовый PR-AUC)	PR-AUC	Brier	Brier константы	alarm_rate_per_100	row_precision	row_recall
4	HGB	0.117	0.162	0.108	0.103	9.173	0.202	0.158
4	Logistic	0.117	0.113	0.109	0.103	5.090	0.135	0.059
4	BOCPD_score_only	0.117	0.136	nan	0.103	4.772	0.133	0.054
13	HGB	0.363	0.389	0.247	0.232	11.413	0.357	0.112
13	Logistic	0.363	0.351	0.271	0.232	1.495	0.455	0.019
13	BOCPD_score_only	0.363	0.365	nan	0.232	4.552	0.373	0.047

Навык раннего предупреждения не подтверждён: PR-AUC лишь немного выше доли событий, Brier не лучше константного прогноза, а при бюджете ложных тревог recall низкий. Нужны размеченные события и ряды длиннее; сейчас честный вывод — детекторы реагируют на уже начавшийся сдвиг, предсказывать его заранее по этим признакам не получается.




Детекторы на инъекциях в реальные остатки


Реальное событие: паводок в Орске 5.04.2024 — ни один детектор не сработал в окне 3 мес.
Орск · Все категории





Ложная тревога ВОСПД (07.2024): всплеск без продолжения
Кесовогорский · Общественное питание



Срабатывание ВОСПД (08.2024): отклонение сохраняется
Хайбуллинский · Продовольствие



Три реальных примера: событие, ложная тревога, срабатывание



Недельные ряды: детекторы и раннее предупреждение

6. Новости и внешние события

«Новости» здесь — это **датированные официальные события**, а не текстовый корпус: решения Банка России по ключевой ставке (cbr.ru; `available_at` = дата вступления в силу, чтобы не заглядывать вперёд) и реестр из 7 региональных событий со ссылками. Признаки на якорю а: уровень ставки, её изменения за 3 и 6 мес., месяцев с последнего изменения, тяжесть недавних событий в МО и в регионе (окно 3 мес.). Текстовые новости (Интерфакс, Lenta, GDELT) не собирались.

Сравнение — одна быстрая конфигурация HGB на одной сетке; плацебо: реестр переносится на случайные МО и месяцы (5 повторов), ставка сдвигается назад на случайные 3–12 мес. (остаётся только прошлым).

Изменение MAE к базе без новостей, % (положительное — лучше). Тест:

Вариант	1	3	6	12
база	0.00	0.00	0.00	0.00
плацебо: ставка + события	-0.75	-0.40	-0.21	0.20
плацебо: события	-0.05	-0.15	0.14	0.06
реальные признаки (среднее 3 вариантов)	-1.01	-1.87	-2.50	-0.15

Validation:

Вариант	1	3	6	12
база	0.00	0.00	0.00	0.00
плацебо: ставка + события	0.85	-0.11	0.11	0.00
плацебо: события	-0.00	0.07	0.00	0.00
реальные признаки (среднее 3 вариантов)	0.55	1.92	0.07	0.00


MAE по вариантам на тесте:

Вариант	1	3	6	12
+key_rate	500.8	743.4	894.2	601.8
+key_rate+events	500.8	743.4	902.8	601.9

Вариант	1	3	6	12
+regional_events	493.4	723.1	866.0	600.5
base_no_news	493.4	723.1	866.0	600.5
placebo_events_0	493.4	723.1	866.0	600.5
placebo_events_1	493.4	723.1	866.0	600.5
placebo_events_2	493.4	723.1	866.0	600.5
placebo_events_3	494.6	728.3	859.9	598.8
placebo_events_4	493.4	723.1	866.0	600.5
placebo_rate+events_0	498.0	725.4	856.9	598.3
placebo_rate+events_1	501.7	726.0	880.7	600.5
placebo_rate+events_2	497.3	736.1	888.5	600.5
placebo_rate+events_3	490.6	716.9	856.1	598.8
placebo_rate+events_4	498.0	725.4	856.9	598.3

Варианты «+regional_events» и часть плацебо-событий дают побитово те же прогнозы, что база: события затрагивают единицы МО из 2016, и бустинг не делает по ним разбиений. Единственные признаки, меняющие прогноз, — ставка ЦБ и её лаги, а они лишь индекс времени в панели из 24 месяцев.

Вывод. Реальные признаки не отличаются от плацебо: полезность новостных признаков для прогноза не подтверждена. Это ожидаемо: ставка ЦБ — признак времени, а в панели всего 24 месяца, и он не может выучиться на разрезе МО; региональные события затрагивают единицы МО из 2016.




Новостные признаки против плацебо

7. Недельный nowcast

Недельные ряды роста г/г идут по 27.09.2026, месячные — по 08.2026. Для целевого месяца по уже вышедшим неделям оценивается г/г и переводится в уровень: $\text{уровень} = \text{уровень}_{\{M-12\}} \times (1 + \text{yoу}/100)$. Доступность недели консервативна (период + 7 дней), поправка смещения считается только по завершённым ранее месяцам, параметры не подбирались. Национальный уровень, 12 тестовых месяцев $\times$ 5 категорий (те же, что в N01):

Метод	n	MAE, млрд руб.
Nowcast(weeks=1,calibrated=False)	60	136.4
Nowcast(weeks=1,calibrated=True)	60	72.6
Nowcast(weeks=2,calibrated=False)	60	137.4
Nowcast(weeks=2,calibrated=True)	60	68.9
Nowcast(weeks=3,calibrated=False)	60	130.0
Nowcast(weeks=3,calibrated=True)	60	65.9
Nowcast(weeks=all,calibrated=False)	60	124.8
Nowcast(weeks=all,calibrated=True)	60	62.0
h=1 DevWeightedEnsemble	60	70.1
h=1 LastValue	60	177.2
h=1 SeasonalGrowth	60	66.0

Без поправки смещения недельный nowcast плох (MAE 125–137): ряды СберИндекса по транзакциям не равны месячному набору, согласованному с Росстатом, и поправка по прошлым месяцам обязательна. С поправкой: по одной неделе месяца — хуже h=1-ансамбля и SeasonalGrowth, по двум — лучше ансамбля, по трём сравним с SeasonalGrowth, по полному месяцу — ниже обоих (62.0 против 70.1 и 66.0). Выигрыш скромный и на 60 наблюдениях; это nowcast с частичной информацией целевого месяца, а не прогноз h=1.



Недельный nowcast против h=1


8. Прогноз 2025 и независимая проверка

Прогноз на 12 месяцев 2025 г. построен от origin = 12.2024 и заморожен вместе с SHA256 (`prospective/`); фактов по МО за 2025 нет, и скрипт `scripts/score_prospective.py` посчитает MAE, когда они появятся.

Санити-проверка по национальным фактам 2025 г. (модель их не видела): средний по МО г/г рост прогноза против национального г/г роста, среднее модуля разницы, п.п.:

index	Категория	ensemble	prophet	structural
0	Все категории	2.31	5.48	2.34
1	Общественное питание	28.70	32.63	35.81
2	Продовольствие	3.50	8.39	6.43

Это проверка согласованности (выборка МО без весов не равна стране), а не оценка точности на уровне МО. У ансамбля подразумеваемый рост ближе к национальному, чем у Prophet, во всех трёх категориях, но для «Общественного питания» разрыв велик у обеих моделей (около 29–33 п.п.): национальный общепит в 2025 г. рос заметно быстрее, чем предполагает любая из моделей; причина (состав категории, отличие от муниципальной выборки) не исследована.



Прогноз 2025 против национального факта

9. Ограничения

- Всего 24 месяца: сезонность по МО не оценивается, $h=12$ на validation проверяется один месяц; протокол валидации — допущение.
- Тест — 6 целевых месяцев; месячные интервалы поэтому широки. Общие шоки месяца (например, декабрьский пик) коррелируют по всем МО, и bootstrap по МО их не отражает.
- Модели обучались на последней версии данных; даты публикации и пересмотры неизвестны.
- Foundation-модели оценены без дообучения; TimesFM — только на подвыборке 200 МО; возможное пересечение их обучающих данных с 2023–2024 гг. проверить нельзя.
- Метки шоков по МО отсутствуют: оценка детекторов опирается на инъекцию, 4 события из реестра и гроху-разметку.
- «Новости» — не текстовый корпус, а короткий реестр и решения ЦБ.
- В панели 2 016 МО из 2 594 в справочнике (73 региона из 85): МО, не прошедшие порог качества СберИндекса, отсутствуют (например, Белгород, Курск, Краснодар); 1 044 неполных ряда исключены.

10. Воспроизведение

```
conda env create -f environment.yml && conda activate sber # Python 3.12
bash scripts/get_data.sh # открытые данные конкурса -> data/raw/
make municipal # Prophet, Chronos, структурная модель, ансамбль, м
make shocks # детекторы и недельные ряды
make report # отчёт, слайды, лендинг
```