

Прогноз потребительских расходов муниципалитетов и ранние сигналы сдвигов

Отчёт построен автоматически из результатов запуска `municipal_20261004T140239Z`. Данные: СберИндекс, безналичные расходы на жителя по 12 096 рядам (2016 МО × 6 категорий), январь 2023 – декабрь 2024. Численные утверждения ниже прочитаны из файлов результатов. Каталог обученных моделей и все метрики: `docs/MODELS_AND_METRICS_RU.md`.

Резюме

Исходные результаты ниже сохранены. Аудит от 07.10.2026 уточнил ретроспективный характер весов и отсутствие стандартной гарантии исходных интервалов; новые эксперименты выполнены после просмотра теста и приведены в разделе 11.

- **Прогнозы 1/3/6/12 мес.** Ансамбль на тесте имеет MAE 440/514/466/583 руб. против 640/719/736/1093 у Prophet, то есть на 31/28/37/47% меньше. Выбор моделей и весов заморожен до открытия теста.
- **Откуда выигрыш.** Основной вклад — национальные ряды с 2018 г.: у МО всего 24 месяца, поэтому сезонность и рост берутся из страны, а по МО оценивается уровень и небольшая поправка. Абляция показывает вклад в явном виде.
- **Фундаментальные модели** (Chronos-Bolt, Chronos-2, Chronos-2 с национальной ковариатой, TimesFM на подвыборке) без дообучения на таких коротких рядах уступают Prophet на горизонтах ≥ 3 (на $h=1$ Chronos-2 с ковариатой лучше) и получили нулевой вес в ансамбле.
- **Детекторы CUSUM / Page–Hinkley / BOCPD** сравнены тремя способами и на недельных реальных рядах; победитель зависит от способа разметки. **Раннее предупреждение: навык не подтверждён.**
- **Новости** как датированные официальные события (ставка ЦБ, реестр) не показали пользы относительно плацебо.
- **Недельный nowcast** национального уровня с поправкой смещения лучше $h=1$ -ансамбля при ≥ 2 неделях месяца; без поправки он непригоден.
- Прогноз на 2025 г. по МО заморожен для будущей проверки.

1. Данные

Источник	Что	Период	Использование
СберИндекс, <code>consumption.parquet</code>	безналичные расходы на жителя, руб./мес., 6 категорий	2023-01...2024-12	цель; 12096 полных рядов, 1044 неполных исключены
Справочник МО (<code>t_dict_municipal</code>)	регион, тип, координаты, интервалы действия	срез 2024	статические признаки, сопоставление событий
<code>market_access.parquet</code>	индекс доступности рынков	2024	статический признак (log)
Национальные расходы СберИндекса	5 категорий, млрд руб./мес.	2018-12...2026-08	приор: сезонность и рост только по данным $\leq$ origin
Недельный рост г/г (46 категорий), активность	недельные ряды	2021/2023...2026-09	детекторы, nowcast
ЦБ РФ: ключевая ставка	по дням	2018...2026	новостные/макро-признаки
Реестр событий	7 событий со ссылками	2023–2024	событийная оценка детекторов

Лицензия данных СберИндекса — CC BY-SA 4.0. Все входные данные хранятся локально в `data/inputs/` и исключены из Git. `make data` проверяет их наличие без скачивания; список файлов — `docs/INPUT_DATA_RU.md`.

2. Протокол оценки

Правила организатора мне неизвестны, поэтому использован «конкурсный» протокол, описанный в открытых работах участников: validation — цели янв.–июнь 2024, test — цели июль–декабрь 2024, расширяющееся окно, прогноз горизонтов

1/3/6/12 из каждого origin с историей не менее 6 месяцев. **Допущение подлежит сверке с официальными правилами.**

- 1. Для каждого origin и каждого ряда используются только значения $\leq$ origin; direct-метки обучения — только с целью $\leq$ origin (проверено тестами `tests/test_municipal.py`: изменение будущих значений не меняет признаки, метки и национальные приоры).
- 2. Конфигурация структурной модели и веса ансамбля выбраны **no validation**; `frozen_selection.json` записан до подсчёта метрик теста. В исходном запуске после первого показа теста модели, кандидаты и веса не менялись; изменения касались только расчёта Prophet для origin 12.2024 (нужен для прогноза 2025, на тест не влияет) и оформления. Значительная часть решений (дрейф без экстраполяции за обученный горизонт, сжатие 0.25) принята по validation после того, как первая версия модели провалилась на $h=6$.
- 3. Метрика — MAE в рублях на жителя по всей сетке (сетки у всех моделей совпадают, покрытие 100%), дополнительно R^2 по уровню и по изменению.
- 4. Неопределённость — парный bootstrap по МО (1000 повторов) и по целевым месяцам (6 месяцев).
- 5. Допущения: значение месяца origin известно на origin; актуальная версия данных (без пересмотров); validation для $h=12$ содержит один целевой месяц (2024-06).

3. Модели

- **Baseline'ы:** LastValue; SeasonalNaive (то же значение год назад, а если нет — LastValue); **Prophet** (месячные даты, настройки по умолчанию, годовая сезонность `auto` включается только при истории >2 лет; настройки организатора неизвестны).
- **Национальный путь (NatPath):** прогноз = локальный уровень (среднее по последним 3 месяцам, скорректированное на реализованное национальное изменение) $\times$ национальное SeasonalGrowth-изменение от origin до цели (сезонность и темп роста из национальных рядов; соответствие муниципальных категорий национальным задано заранее).
- **SeasonalNaive_NatGrowth:** значение того же месяца год назад $\times$ национальный годовой рост.
- **StructHGB:** градиентный бустинг (MAE) по остатку относительно NatPath: признаки — локальные импульсы относительно страны, шум, сезонные разности, региональные и категорийные средние, статические признаки МО. Дрейф на месяц умножается на горизонт, **но не дальше обученного** ($h \leq origin-5$) и сжимается на валидации (коэффициент 0.25).
- **Foundation:** Chronos-Bolt-small, Chronos-2 (zero-shot), Chronos-2 + национальный путь как ковариата, TimesFM-2.5 (подвыборка). Ревизии чекпойнтов в `artifacts/municipal_runs/_foundation/*_meta.json`.
- **Ансамбль:** веса минимизируют MAE на validation (линейная программа, симплекс), отдельно по горизонтам.
- **Интервалы:** эмпирические квантили на общей validation; стандартная conformal-гарантия не заявляется.

4. Прогноз 1/3/6/12 мес.

Результат исходного запуска. На ретроспективном тесте (цели июль–декабрь 2024, 12 096 рядов) замороженный ансамбль имеет MAE **440 / 514 / 466 / 583 руб. на жителя** для горизонтов 1 / 3 / 6 / 12 мес. против **640 / 719 / 736 / 1093** у Prophet по умолчанию. Снижение — **31% / 28% / 37% / 47%**. Парный bootstrap по МО (1000 повторов) даёт 95% интервалы разности MAE строго ниже нуля на всех горизонтах; bootstrap по шести целевым месяцам (общий шок месяца не усредняется по МО) также исключает ноль на всех горизонтах. R^2 по изменению относительно origin (динамика, а не масштаб МО): ансамбль 0.67 / 0.74 / 0.84 / 0.69, Prophet 0.13 / 0.42 / 0.53 / -0.44. Обычный R^2 по уровню 0.97–0.996 у всех моделей и почти ничего не показывает: уровень определяется масштабом МО.

Таблица теста

Модель	MAE h=1	MAE h=3	MAE h=6	MAE h=12	Среднее	Δ к Prophet, % (среднее)
Ensemble	439.6	513.9	466.1	583.4	500.7	37.2

Модель	MAE h=1	MAE h=3	MAE h=6	MAE h=12	Среднее	Δ к Prophet, % (среднее)
SeasonalNaive_NatGrowth	546.7	542.6	529.0	612.4	557.7	30.0
NatPath_K1	402.8	724.3	873.2	612.4	653.2	18.1
StructHGB	499.9	736.4	883.1	606.2	681.4	14.5
NatPath_K3	525.6	757.9	757.1	686.5	681.8	14.5
Prophet	640.4	718.6	736.5	1092.8	797.1	0.0
LocalOnlyHGB	665.9	774.7	930.3	1165.1	884.0	-10.9
Chronos2_NatCov	506.2	721.8	969.8	1533.3	932.8	-17.0
LastValue	624.4	863.8	1124.2	1288.6	975.3	-22.4
LocalBase_K3	691.0	815.6	1005.7	1534.5	1011.7	-26.9
Chronos2	612.9	877.1	1360.7	1817.0	1166.9	-46.4
SeasonalNaive	1288.6	1288.6	1288.6	1288.6	1288.6	-61.7
ChronosBolt	706.7	1024.2	1603.4	1986.0	1330.1	-66.9

Что даёт национальная информация (абляция)

Вариант	MAE h=1	MAE h=3	MAE h=6	MAE h=12
Локальный уровень (без национальных данных)	691.0	815.6	1005.7	1534.5
+ GBM без национальных данных	665.9	774.7	930.3	1165.1
Национальный путь (NatPath_K3)	525.6	757.9	757.1	686.5
NatPath + остаточный GBM (StructHGB)	499.9	736.4	883.1	606.2

Национальный путь (сезонность и темп роста из рядов с 2018 г., только по данным до origin) снижает среднюю MAE с 1012 до 682 (33%). Остаточный GBM поверх национального пути даёт смешанный эффект: лучше на h=1 (526 → 500) и h=12 (687 → 606), но хуже на h=3 и h=6; в среднем 682 → 681. Основной вклад вносит национальный приор, а не нелинейная модель по МО. Причина: у МО всего 6–23 месяца истории, и ни сезонность, ни годовой рост по такому ряду оценить нельзя.

Веса ансамбля (подобраны на validation)

Модель	1	3	6	12
Prophet	0.25	0.47	0.27	0.28
SeasonalNaive_NatGrowth	0.35	0.41	0.66	0.64
StructHGB	0.40	0.12	0.06	0.07

Веса найдены линейной программой (минимум MAE на симплексе); для h=12 использованы пары h=6 и h=12, потому что на validation у h=12 один целевой месяц. Foundation-модели получили нулевой вес: на validation они не лучше выбранных кандидатов.

По категориям (среднее по 4 горизонтам)

Категория	Ensemble	Prophet	Δ, %
Все категории	1236.3	2319.8	46.7
Здоровье	137.6	201.0	31.5
Маркетплейсы	710.7	649.0	-9.5
Общественное питание	132.7	225.8	41.2
Продовольствие	652.1	1138.5	42.7
Транспорт	135.0	248.3	45.6

В категории «Маркетплейсы» с очень быстрым ростом и сильной сезонностью ансамбль не лучше Prophet — это слабое место, которое стоит исправлять отдельным национальным приором для маркетплейсов.

По размеру ряда (терцили уровня внутри категории)

Терциль	Ensemble	Prophet	Δ, %
T1	446.9	626.0	28.6
T2	461.7	706.8	34.7
T3	593.6	1058.6	43.9

Интервалы

Горизонт, мес.	Номинал	Покрытие на тесте	Средняя полуширина (отн.)
1.000	0.900	0.889	0.166
3.000	0.900	0.874	0.193
6.000	0.900	0.941	0.274
12.000	0.900	0.944	0.417

Исходные интервалы используют ту же validation, где выбирались веса. Стандартная гарантия split-conformal не заявляется. Отдельная последовательная калибровка проверена в дополнении от 07.10.2026.

Фундаментальные модели (zero-shot)


Модель	MAE h=1	MAE h=3	MAE h=6	MAE h=12
Chronos2	612.9	877.1	1360.7	1817.0
Chronos2_NatCov	506.2	721.8	969.8	1533.3
ChronosBolt	706.7	1024.2	1603.4	1986.0
Prophet	640.4	718.6	736.5	1092.8

Chronos-Bolt-small и Chronos-2 использованы без дообучения, контекст — `history[:origin+1]`. Версия `Chronos2_NatCov` получает национальный путь как known-future ковариату. Результат: на коротких рядах (6–23 точки) zero-shot модели уступают Prophet на $h \geq 3$; на $h=1$ Chronos-2 и особенно Chronos-2 с ковариатой чуть лучше Prophet. Ковариата заметно улучшает Chronos-2 на всех горизонтах, но не доводит его до Prophet на $h \geq 6$. Возможное пересечение обучающих корпусов чекпойнтов с 2023–2024 гг. проверить нельзя, поэтому это оценка современной модели, а не исторического deployment.

TimesFM-2.5 (200M) на CPU считает ~0,13 с на ряд, поэтому оценён на случайной подвыборке из 200 МО (1200 рядов, все категории; seed 42), остальные модели сравнены на тех же рядах:


Модель	1	3	6	12	среднее
Ensemble	427.7	498.0	450.3	583.4	489.8
SeasonalNaive_NatGrowth	533.3	527.0	510.1	590.9	540.3
NatPath_K3	506.1	723.2	720.0	672.2	655.4
Prophet	622.1	694.8	709.2	1077.6	775.9
Chronos2_NatCov	497.1	703.4	946.1	1494.1	910.2
LastValue	610.4	844.1	1094.5	1234.1	945.8
TimesFM	549.3	785.8	1245.0	1630.3	1052.6
Chronos2	603.5	869.3	1327.6	1757.5	1139.5

Тест (июль-декабрь 2024): MAE по горизонтам, 12 096 рядов




MAE по горизонтам на тесте


Выигрыш у Prophet (95% bootstrap по MO)



Снижение MAE относительно Prophet с 95% bootstrap по MO



Веса ансамбля



MAE по категориям и размеру ряда



Карта выигрыша у Prophet по МО (категория «Все категории»)

5. Структурные изменения: обнаружение и предупреждение

Детекторы CUSUM, Page-Hinkley и BOCPD подаются стандартизированными остатками прогноза $h=1$, выпущенного до наблюдения (национальный путь $\times$ локальный уровень). Масштаб остатка считается только по прошлому и сжимается к масштабу категории. Пороги подобраны на месяцах 10–17 при бюджете **1 ложная тревога на 100 ряд-месяцев**, оценка — на месяцах 18–23. Реальных размеченных шоков по МО у нас нет, поэтому оценка идёт тремя способами диагностики, и ни один из них не называется «истиной».

А. Инъекция известных сдвигов в реальные остатки

Сдвиг $\pm 1.5/2.5/4\sigma$ добавляется в 5% рядов (604 события) на месяцы 18–20; остальные 95% остаются реальными и служат фоном для ложных тревог. Пять независимых повторов.

Метод	Порог	Precision	Recall	F1	$\pm$ F1 (5 повторов)	Медиана задержки, мес.	Ложных тревог / 100 ряд-мес.
CUSUM	10.000	0.161	0.449	0.237	0.004	1.400	1.914
PageHinkley	12.000	0.090	0.314	0.140	0.004	1.200	2.716
BOCPD	0.500	0.128	0.353	0.188	0.009	1.000	2.097

Метод	Recall при сдвиге 1.5σ	Recall при сдвиге 2.5σ	Recall при сдвиге 4.0σ
CUSUM	0.22	0.37	0.74
PageHinkley	0.15	0.23	0.54
BOCPD	0.20	0.34	0.51

Частота тревог на тесте выше, чем на калибровке (~2 против ≤1 на 100 ряд-месяцев): в тесте часть тревог — настоящие шоки или сезонные промахи прогноза (Дек–Янв), а не ложные. Поэтому precision здесь консервативна.

В. Реестр датированных событий

В реестре 7 событий (паводки, теракты, обстрелы; ссылки в `data/inputs/event_registry.csv`). Сопоставление с МО по названию внутри региона нашло 6 территорий. Белгорода, Курска и Суджи в панели нет (не прошли порог качества СберИндекса), а для Севастополя, Дербента и Махачкалы сопоставление по названию МО не нашло. Оценимы Орск, Оренбург, Новотроицк (паводок, 04.2024) и Красногорск («Крокус», 03.2024).

event_id	pattern	method	рядов	доля_с_тревогой	макс_z	фон_все_ряды
EV01	Новотроицк	BOCPD	6	0.17	2.84	0.07
EV01	Новотроицк	CUSUM	6	0.00	2.84	0.09
EV01	Новотроицк	PageHinkley	6	0.00	2.84	0.02
EV01	Оренбург	BOCPD	6	0.00	2.74	0.07
EV01	Оренбург	CUSUM	6	0.00	2.74	0.09
EV01	Оренбург	PageHinkley	6	0.00	2.74	0.02
EV01	Орск	BOCPD	6	0.17	3.43	0.07
EV01	Орск	CUSUM	6	0.00	3.43	0.09
EV01	Орск	PageHinkley	6	0.00	3.43	0.02
EV05	Красногорск	BOCPD	6	0.00	2.80	0.07
EV05	Красногорск	CUSUM	6	0.00	2.80	0.06
EV05	Красногорск	PageHinkley	6	0.00	2.80	0.01

Отклик на реальные события слабый: максимум |z| 2.7–3.4σ, тревоги единичны (BOCPD по 1 из 6 категорий в Орске и Новотроицке), в других случаях — нет. Это не доказывает отсутствие эффекта — месячная сумма по всем категориям сглаживает локальный шок, — но и не подтверждает работоспособность детекторов на реальных событиях.

С. Offline-сегментация как проху-разметка

F1 по меткам offline-сегментации z-рядов (3000 случайных рядов, тест). Разметка не независима от формы z и не равна истине, поэтому это анализ чувствительности: ранжирование методов зависит от типа разметки (на инъекциях выигрывает CUSUM, на offline-метках — BOCPD).

Штраф	BOCPD	CUSUM	PageHinkley
2.000	0.608	0.016	0.220
4.000	0.523	0.019	0.183
8.000	0.359	0.010	0.209

D. Недельные реальные ряды (46 категорий, 151 неделя)

У недельных рядов достаточно длины для оценки на реальных данных: пороги — на первых 55% недель при бюджете 1/100, оценка — на последних 30%. Метки — offline-сегментация со штрафом 16 (чувствительность по штрафам 4/8/16/32 — в `artifacts/weekly_shocks/detector_metrics_proxy_labels.csv`).


method	threshold	n_proxy_events_test	n_alarms_test	event_precision	event_recall	event_f1	false_alarms_per_100_series_weeks	median_delay_weeks
CUSUM	20.000	58	26	0.500	0.224	0.310	0.614	4.000
PageHinkley	24.000	58	34	0.529	0.310	0.391	0.756	3.000
BOCPD	0.900	58	14	0.357	0.086	0.139	0.425	1.000

Е. Раннее предупреждение (вероятность сдвига в окне (t, t+k])

Признаки на момент t: z, средние и максимумы |z| за 4 недели, доля рядов с |z|>2 (ширина шока), оценки трёх детекторов, изменение ключевой ставки ЦБ за 13 недель и недели с последнего изменения. Обучение — на метках, зрелых к границе; между train и test зазор 8 недель.


Окно, нед.	Модель	Доля событий (базовый PR-AUC)	PR-AUC	Brier	Brier константы	alarm_rate_per_100	row_precision	row_recall
4	HGB	0.117	0.162	0.108	0.103	9.173	0.202	0.158
4	Logistic	0.117	0.113	0.109	0.103	5.090	0.135	0.059
4	BOCPD_score_only	0.117	0.136	nan	0.103	4.772	0.133	0.054
13	HGB	0.363	0.389	0.247	0.232	11.413	0.357	0.112
13	Logistic	0.363	0.351	0.271	0.232	1.495	0.455	0.019
13	BOCPD_score_only	0.363	0.365	nan	0.232	4.552	0.373	0.047

Навык раннего предупреждения не подтверждён: PR-AUC лишь немного выше доли событий, Brier не лучше константного прогноза, а при бюджете ложных тревог recall низкий. Нужны размеченные события и ряды длиннее; сейчас честный вывод — детекторы реагируют на уже начавшийся сдвиг, предсказывать его заранее по этим признакам не получается.




Детекторы на инъекциях в реальные остатки


Реальное событие: паводок в Орске 5.04.2024 — ни один детектор не сработал в окне 3 мес.
Орск · Все категории





Ложная тревога ВОСПД (07.2024): всплеск без продолжения
Кесовогорский · Общественное питание



Срабатывание ВОСПД (08.2024): отклонение сохраняется
Хайбуллинский · Продовольствие



Три примера: событие, тревога без события в реестре, срабатывание



Недельные ряды: детекторы и раннее предупреждение

6. Новости и внешние события

«Новости» здесь — это **датированные официальные события**, а не текстовый корпус: решения Банка России по ключевой ставке (cbr.ru; `available_at` = дата вступления в силу, чтобы не заглядывать вперёд) и реестр из 7 региональных событий со ссылками. Признаки на якоря а: уровень ставки, её изменения за 3 и 6 мес., месяцев с последнего изменения, тяжесть недавних событий в МО и в регионе (окно 3 мес.). Текстовые новости (Интерфакс, Lenta, GDELT) не собирались.

Сравнение — одна быстрая конфигурация HGB на одной сетке; плацебо: реестр переносится на случайные МО и месяцы (5 повторов), ставка сдвигается назад на случайные 3–12 мес. (остаётся только прошлым).

Изменение MAE к базе без новостей, % (положительное — лучше). Тест:

Вариант	1	3	6	12
база	0.00	0.00	0.00	0.00
плацебо: ставка + события	-0.75	-0.40	-0.21	0.20
плацебо: события	-0.05	-0.15	0.14	0.06
реальные признаки (среднее 3 вариантов)	-1.01	-1.87	-2.50	-0.15

Validation:

Вариант	1	3	6	12
база	0.00	0.00	0.00	0.00
плацебо: ставка + события	0.85	-0.11	0.11	0.00
плацебо: события	-0.00	0.07	0.00	0.00
реальные признаки (среднее 3 вариантов)	0.55	1.92	0.07	0.00


MAE по вариантам на тесте:

Вариант	1	3	6	12
+key_rate	500.8	743.4	894.2	601.8
+key_rate+events	500.8	743.4	902.8	601.9

Вариант	1	3	6	12
+regional_events	493.4	723.1	866.0	600.5
base_no_news	493.4	723.1	866.0	600.5
placebo_events_0	493.4	723.1	866.0	600.5
placebo_events_1	493.4	723.1	866.0	600.5
placebo_events_2	493.4	723.1	866.0	600.5
placebo_events_3	494.6	728.3	859.9	598.8
placebo_events_4	493.4	723.1	866.0	600.5
placebo_rate+events_0	498.0	725.4	856.9	598.3
placebo_rate+events_1	501.7	726.0	880.7	600.5
placebo_rate+events_2	497.3	736.1	888.5	600.5
placebo_rate+events_3	490.6	716.9	856.1	598.8
placebo_rate+events_4	498.0	725.4	856.9	598.3

Варианты «+regional_events» и часть плацебо-событий дают побитово те же прогнозы, что база: события затрагивают единицы МО из 2016, и бустинг не делает по ним разбиений. Единственные признаки, меняющие прогноз, — ставка ЦБ и её лаги, а они лишь индекс времени в панели из 24 месяцев.

Вывод. Реальные признаки не отличаются от плацебо: полезность новостных признаков для прогноза не подтверждена. Это ожидаемо: ставка ЦБ — признак времени, а в панели всего 24 месяца, и он не может выучиться на разрезе МО; региональные события затрагивают единицы МО из 2016.




Новостные признаки против плацебо

7. Недельный nowcast

Недельные ряды роста г/г идут по 27.09.2026, месячные — по 08.2026. Для целевого месяца по уже вышедшим неделям оценивается г/г и переводится в уровень: $\text{уровень} = \text{уровень}_{\{M-12\}} \times (1 + \text{yoу}/100)$. Доступность недели консервативна (период + 7 дней), поправка смещения считается только по завершённым ранее месяцам, параметры не подбирались. Национальный уровень, 12 тестовых месяцев $\times$ 5 категорий (те же, что в N01):

Метод	n	MAE, млрд руб.
Nowcast(weeks=1,calibrated=False)	60	136.4
Nowcast(weeks=1,calibrated=True)	60	72.6
Nowcast(weeks=2,calibrated=False)	60	137.4
Nowcast(weeks=2,calibrated=True)	60	68.9
Nowcast(weeks=3,calibrated=False)	60	130.0
Nowcast(weeks=3,calibrated=True)	60	65.9
Nowcast(weeks=all,calibrated=False)	60	124.8
Nowcast(weeks=all,calibrated=True)	60	62.0
h=1 DevWeightedEnsemble	60	70.1
h=1 LastValue	60	177.2
h=1 SeasonalGrowth	60	66.0

Без поправки смещения недельный nowcast плох (MAE 125–137): ряды СберИндекса по транзакциям не равны месячному набору, согласованному с Росстатом, и поправка по прошлым месяцам обязательна. С поправкой: по одной неделе месяца — хуже h=1-ансамбля и SeasonalGrowth, по двум — лучше ансамбля, по трём сравним с SeasonalGrowth, по полному месяцу — ниже обоих (62.0 против 70.1 и 66.0). Выигрыш скромный и на 60 наблюдениях; это nowcast с частичной информацией целевого месяца, а не прогноз h=1.



Недельный nowcast против h=1


8. Ретроспективный прогноз 2025 и ожидаемая проверка

Прогноз на 12 месяцев 2025 г. построен от origin = 12.2024 и заморожен вместе с SHA256 (`prospective/`); фактов по МО за 2025 нет, и скрипт `scripts/score_prospective.py` посчитает MAE, когда они появятся.

Санити-проверка по национальным фактам 2025 г. (модель их не видела): средний по МО г/г рост прогноза против национального г/г роста, среднее модуля разницы, п.п.:

index	Категория	ensemble	prophet	structural
0	Все категории	2.31	5.48	2.34
1	Общественное питание	28.70	32.63	35.81
2	Продовольствие	3.50	8.39	6.43

Это проверка согласованности (выборка МО без весов не равна стране), а не оценка точности на уровне МО. У ансамбля подразумеваемый рост ближе к национальному, чем у Prophet, во всех трёх категориях, но для «Общественного питания» разрыв велик у обеих моделей (около 29–33 п.п.): национальный общепит в 2025 г. рос заметно быстрее, чем предполагает любая из моделей; причина (состав категории, отличие от муниципальной выборки) не исследована.



Прогноз 2025 против национального факта

9. Ограничения

- Всего 24 месяца: сезонность по МО не оценивается, $h=12$ на validation проверяется один месяц; протокол валидации — допущение.
- Тест — 6 целевых месяцев; месячные интервалы поэтому широки. Общие шоки месяца (например, декабрьский пик) коррелируют по всем МО, и bootstrap по МО их не отражает.
- Модели обучались на последней версии данных; даты публикации и пересмотры неизвестны.
- Foundation-модели оценены без дообучения; TimesFM — только на подвыборке 200 МО; возможное пересечение их обучающих данных с 2023–2024 гг. проверить нельзя.
- Метки шоков по МО отсутствуют: оценка детекторов опирается на инъекцию, 4 события из реестра и гроху-разметку.
- В исходном опыте новости представлены коротким реестром и решениями ЦБ; расширенный региональный корпус проверен отдельно в дополнении.
- В панели 2 016 МО из 2 594 в справочнике (73 региона из 85): МО, не прошедшие порог качества СберИндекса, отсутствуют (например, Белгород, Курск, Краснодар); 1 044 неполных ряда исключены.

10. Воспроизведение

```
conda env create -f environment.yml && conda activate sber # Python 3.12
make data # локальные входы в data/inputs/, без скачивания
make municipal # Prophet, Chronos, структурная модель, ансамбль, м
make shocks # детекторы и недельные ряды
make report # отчёт, слайды, лендинг
```

11. Доработка исследования после аудита

Перенос национальной динамики на короткие муниципальные ряды

Дополнение от 07.10.2026, запуск `research_20261007T073840_163667Z`. Все эксперименты этого дополнения выполнены после просмотра теста 2024H2. Это анализ устойчивости и новые исследовательские результаты; они не превращают просмотренный тест в независимый. Исходные прогнозы и файлы `prospective/` сохранены.

Исследовательский вопрос и вклад

Можно ли прогнозировать расходы муниципалитета с 6–24 месяцами истории, перенося сезонность и рост из длинных национальных рядов? Гипотеза: основную пользу приносит общий национальный путь, а локальная нелинейная коррекция даёт небольшую прибавку. Проверяем MAE в рублях, WAPE, медианную относительную ошибку и долю выигравших территорий на общей сетке.

Это прикладная проверка переноса информации между уровнями, а не заявка на новый алгоритм ансамблирования или conformal prediction. Общие и локальные модели обсуждаются в [Montero-Manso](#) и [Hyndman](#). Наше отличие — явное разложение на муниципальный уровень и национальную траекторию, проверка доступности параметров и разбор короткой истории в этой панели. Полноценного обзора всех решений конкурса нет.

Сильные базы и цена усложнения

MAE на просмотренном тесте, полная панель 2 016 МО × 6 категорий:

Модель	h=1	h=3	h=6	h=12	Среднее по h
Ensemble	439.606	513.868	466.104	583.405	500.746
DevBlend_NoHGB	445.466	508.998	462.879	595.033	503.094
EqualBlend_NoHGB	454.374	541.812	525.439	628.111	537.434
PastOnlyBlend	454.006	539.040	576.824	628.111	549.495
SeasonalNaive_NatGrowth	546.714	542.560	528.960	612.419	557.664
Prophet	640.425	718.560	736.483	1092.845	797.078
RidgeSeasonal_DevSelected	601.014	713.457	787.697	969.596	767.941
WeeklyMarketplacePrior	480.561	507.459	509.180	619.345	529.136

DevBlend_NoHGB: Prophet + SeasonalNaive_NatGrowth + NatPath_K3, LAD-веса на validation. EqualBlend_NoHGB: те же три модели с фиксированными равными весами. Прибавка исходного ансамбля с HGB относительно DevBlend_NoHGB по средней MAE — **0.47%**. Уникальный вклад HGB мал; дополнительная сложность пока не обоснована большим выигрышем.

NatPath_K1 имеет MAE 402.8 на h=1, ниже 439.6 у исходного ансамбля. Исходный ансамбль не является лучшим на каждом горизонте; выбирать победителя по текущему тесту для финального утверждения нельзя.

Разность MAE исходного ансамбля и сильного SeasonalNaive_NatGrowth, 95% bootstrap по шести целевым месяцам (отрицательное — лучше ансамбль):

h	mae_difference	month_ci_low	month_ci_high
1.000	-107.108	-162.146	-38.208
3.000	-28.693	-93.034	32.860
6.000	-62.856	-106.250	-18.664
12.000	-29.015	-83.609	19.080

На h=3 и h=12 интервалы включают ноль. Шесть месяцев недостаточны для уверенного вывода об устойчивости по времени; пространственный размер панели не добавляет независимых временных режимов. Bootstrap по месяцам здесь

диагностический: временная зависимость и малое число месяцев ограничивают его интерпретацию.

Явно сезонный Prophet проверен с Fourier order=2, двумя вариантами регуляризации, выбранными по validation. Все модели сравнены на **одних и тех же 25 случайных МО / 150 рядах**, seed=42; выполнено 5 700 подгонок. Это ограниченное исследование чувствительности, не официальный baseline и не полный поиск параметров.

model	1	3	6	12
Ensemble	446.395	520.725	445.846	547.694
PastOnlyBlend	459.294	551.593	570.228	597.779
Prophet	674.727	754.886	732.361	1016.425
ProphetSeasonal_DevSelected	581.839	628.093	690.507	1917.265
RidgeSeasonal_DevSelected	626.596	743.277	790.271	995.276
SeasonalNaive_NatGrowth	510.407	504.155	495.496	623.672

Доступность параметров во времени

Исходные веса выбирались по целям до июня 2024 включительно. На h=12 прогнозы тестовых целей июля–декабря 2024 имеют origin июль–декабрь 2023: выбранные позднее веса тогда были недоступны. Это ретроспективная проверка метода, отделённая от численного as-of backtest.

PastOnlyBlend подбирает веса только по ошибкам с target ≤ origin–2; последние два зрелых месяца оставлены калибровке. При менее двух месяцев подбора используются фиксированные равные веса. Для h=12 на данном тесте нет зрелых меток: используется именно fallback, а не параметры, обученные на будущих фактах. Случайная подвыборка подбора ограничена 3 000 строками, seed=42. Модели в этом сравнении не используют статические признаки среза 2024.

Сохраняются: `past_only_selection_audit.csv`, `calibration_audit.csv`, `original_selection_time_audit.csv`.
Ограничения: последняя версия данных, неизвестные задержки публикаций месячных значений и выбор полных рядов по всей истории. «As-of» относится к численным входам и весам при допущении доступности месяца origin; историческую доступность современного кода или винтажей оно не доказывает.

Интервалы: калибровка отделена от подбора

Последовательная калибровка использует ошибки ранее выданных прогнозов; её целевые месяцы исключены из текущего подбора весов. Из-за коррелированных территорий, короткой истории и изменения распределения гарантии обменного split-conformal не заявляются. [Adaptive Conformal Inference](#) показывает важность отдельного рассмотрения изменения распределения; адаптивный алгоритм этой статьи здесь не реализован.

Среднее эмпирическое покрытие по категориям и месяцам:

h	availability	coverage	relative_half_width
1.000	1.000	0.859	0.159
3.000	1.000	0.867	0.244
6.000	1.000	0.927	0.304
12.000	0.000	nan	nan

На h=1 и h=3 есть недопокрытие относительно 90%. На h=12 интервал недоступен: нулевую доступность нельзя заменять высоким покрытием. Полный разрез по категориям и месяцам — `past_only_intervals.csv`.

Исходные интервалы были рассчитаны по той же validation, где выбирались веса. Их старые значения сохранены как эмпирическая диагностика; стандартная гарантия split-conformal к ним неприменима.

Внешние данные: маркетплейсы и инфляция

В имеющейся выгрузке найден недельный рост расходов на маркетплейсах с 12.11.2023. Новый prior использует медиану доступных недель последних 13 недель (минимум 4) и расход МО того же месяца год назад. Доступность недели = период + 7 дней; неизвестный или недоступный prior заменяется SeasonalNaive_NatGrowth. Чужая будущая неделя не используется. Для остальных категорий прогноз базы не меняется.

MAE только по маркетплейсам, одна сетка:

Модель	1	3	6	12
Ensemble	521.442	575.929	661.425	1083.842
PastOnlyBlend	561.048	569.589	541.311	1131.560
WeeklyMarketplacePrior	617.427	747.900	845.292	1357.207
SeasonalNaive_NatGrowth	1014.348	958.511	963.972	1315.653

Источник категории «Непродовольственные товары» слишком широк для маркетплейсов; недельная категория совпадает по названию, но равенство транзакционного охвата не подтверждено. Улучшение относительно прежнего сезонного правила есть на h=1/3/6, на h=12 его нет; замена всего исходного ансамбля этим правилом не обоснована. Такой prior теперь можно проверять на следующем независимом периоде.

Для интерпретации добавлен национальный ИПЦ декабря 2024 к декабрю 2023 из [Росстата](#), опубликованный 15.01.2025. Он не подаётся в исторические прогнозы 2024 года.

category	price_group	nominal_yoy_mean_pct	deflated_proxy_yoy_mean_pct	cpi_yoy_pct
Все категории	Все товары и услуги	14.353	4.413	9.520
Продовольствие	Продовольственные товары	5.958	-4.585	11.050

Дефлированный показатель — диагностический гроху. Он не отделяет объём потребления от изменений структуры корзины, охвата платежей и состава клиентов. Для общепита, здоровья и маркетплейсов соответствующий точный дефлятор не найден; широкие индексы не подставляются как эквивалент.

Экономическая интерпретация и устойчивость

Средний г/г рост по месяцам 2024: национальный гроху и муниципальная панель отличаются; соответствие категорий является допущением.

category	mean_local_yoy_pct	median_local_yoy_pct	national_proxy_yoy_pct
Все категории	14.867	14.928	16.088
Здоровье	10.227	10.702	17.328
Маркетплейсы	64.686	56.594	17.328
Общественное питание	19.925	17.378	23.131
Продовольствие	10.126	10.695	14.773
Транспорт	8.598	9.157	14.952

Прогноз 2025: чувствительность к агрегированию (среднее по 12 месяцам):

category	mean_mo_yoy_pct	ratio_of_sums_yoy_pct	national_actual_yoy_pct
Все категории	16.026	16.166	14.153
Общественное питание	20.753	20.349	49.456
Продовольствие	12.490	12.581	12.343

По общепиту переход от среднего роста МО к отношению сумм почти не устраняет разрыв с национальным фактом. **Различие весов этих двух способов не объясняет расхождение.** Причина остаётся неустановленной: нужны проверка определений категорий, охвата и возможных изменений измерения. Отношение сумм расходов на жителя не является суммой денежных расходов страны: для неё нужны веса населения.

Доля МО с улучшением против сильной сезонной базы:

model	comparator	h	municipal_win_share
Ensemble	SeasonalNaive_NatGrowth	1	0.804
Ensemble	SeasonalNaive_NatGrowth	3	0.569
Ensemble	SeasonalNaive_NatGrowth	6	0.833
Ensemble	SeasonalNaive_NatGrowth	12	0.603
PastOnlyBlend	SeasonalNaive_NatGrowth	1	0.760
PastOnlyBlend	SeasonalNaive_NatGrowth	3	0.519
PastOnlyBlend	SeasonalNaive_NatGrowth	6	0.322
PastOnlyBlend	SeasonalNaive_NatGrowth	12	0.481

Категории: MAE, WAPE и медианная относительная ошибка; значения усреднены по месяцам и горизонтам:

model	value	mae	wape	median_ape
Ensemble	Все категории	1236.331	0.039	0.033
Ensemble	Здоровье	137.634	0.093	0.085
Ensemble	Маркетплейсы	710.659	0.132	0.124
Ensemble	Общественное питание	132.715	0.099	0.104
Ensemble	Продовольствие	652.107	0.052	0.046
Ensemble	Транспорт	135.029	0.071	0.061
PastOnlyBlend	Все категории	1399.182	0.044	0.038
PastOnlyBlend	Здоровье	165.339	0.112	0.106
PastOnlyBlend	Маркетплейсы	700.877	0.129	0.121
PastOnlyBlend	Общественное питание	153.981	0.114	0.119
PastOnlyBlend	Продовольствие	726.011	0.058	0.053
PastOnlyBlend	Транспорт	151.581	0.080	0.070

Десять регионов с наибольшим средним WAPE исходного ансамбля:

value	mae	wape	median_ape
Республика Калмыкия	564.178	0.088	0.116
Республика Саха (Якутия)	945.527	0.082	0.095
Сахалинская область	933.798	0.081	0.105
Чукотский автономный округ	1610.064	0.081	0.105
Амурская область	690.194	0.079	0.096
Республика Тыва	591.815	0.079	0.092
Ненецкий автономный округ	1014.389	0.078	0.077
Магаданская область	1160.715	0.077	0.089
Ямало-Ненецкий автономный округ	975.719	0.071	0.090
Республика Марий Эл	450.369	0.070	0.085

Результаты относятся к полной наблюдаемой когорте, а не ко всем МО России. В «Все категории» входят расходы подкатегорий; средняя метрика по шести категориям не является суммой экономической полезности. Итоговые веса категорий следует согласовать с регламентом.

Официальные события и действие после тревоги

Добавлены три кейса с подтверждающими официальными публикациями. Дата события, дата публикации и дата проверки сохранены отдельно. Это внешние события, **не независимые подтверждённые метки сдвига расходов**.

event_id	title	matched_territories	evaluable	period_role	reason
VC01	Эвакуация жителей Орска после повреждения дамбы	1	True	calibration	available
VC02	Пожар и нападение в Крокус Сити Холле	1	True	calibration	available
VC03	Паводок в Уссурийске	1	False	outside_calibration	no_matched_rows_or_insufficient_history

event_id	method	series	detected_share	median_delay
VC01	AbsZ	6	0.000	nan
VC01	BOCPD	6	0.167	3.000
VC01	CUSUM	6	0.000	nan
VC01	PageHinkley	6	0.000	nan
VC02	AbsZ	6	0.000	nan
VC02	BOCPD	6	0.000	nan
VC02	CUSUM	6	0.000	nan
VC02	PageHinkley	6	0.000	nan

Два оценимых события относятся к периоду настройки порогов: это описательные кейсы, а не независимый событийный тест. Уссурийск сопоставлен, но история для стандартизации слишком коротка. BOCPD реагирует на одну из шести категорий Орска; реакция остальных методов и на Красногорск слабая. Отсутствие тревоги не доказывает отсутствие экономического воздействия.

Добавлена база AbsZ: порог абсолютного стандартизованного остатка, подобранный по той же калибровке при бюджете 1 тревога на 100 ряд-месяцев; cooldown=3 месяца. Тревоги без события в коротком реестре сохранены в `unmatched_alarms.csv`; достоверно назвать их ложными нельзя.

Проверена связка «тревога → коррекция будущего прогноза». После сигнала используем только доступный остаток, сжатие 0.5, ограничение log-коррекции ±0.3 и затухание за 3 месяца. Параметры заданы для этого исследовательского опыта, по тесту не оптимизировались. Разность MAE относительно неизменённого NatPath_K3 (отрицательное — лучше):

method	1	3	6	12
AbsZ	-0.553	-0.696	3.683	-0.884
BOCPD	-11.453	-7.820	0.363	0.000
CUSUM	-2.826	4.705	5.372	0.000
PageHinkley	-7.708	-3.424	0.030	0.000

Эффект небольшой и зависит от горизонта; раннее предупреждение будущего события этим не доказано. Действие начинается после наблюдения сигнала. Сравнение не заменяет существующую оценку детекторов на инъекциях и недельных проху-метках.

Сценарий использования

Пользователь — региональный аналитик спроса. Он выбирает МО и категорию, смотрит прогноз расходов и диапазон неопределённости, сопоставляет отклонение с общим национальным ростом. При тревоге проверяет качество данных и официальные события; решение о коррекции принимает после проверки. Возможный результат — приоритет территории для ручного анализа. Экономия бюджета или эффект для бизнеса не измерены и не заявляются.

Демонстрация: `presentation/research_demo.html`, без сервера и внешних библиотек. Три реальных кейса показывают факт, прогноз до наблюдения и тревоги; отдельная таблица показывает замороженный ретроспективный прогноз 2025, фактов МО за этот год нет.

Воспроизводимость и границы готовности

Полный снимок среды в `requirements.lock.txt`; `environment.yml` теперь использует его. HiGHS и BLAS ограничены одним потоком; команды Make используют пониженный приоритет. Исходный запуск воспроизведён по сохранённым прогнозам. `make verify` проверяет версии пакетов, SHA256 входов, доступность недельных данных, зрелость/разделение меток, сохранность файлов `prospective/` и совпадение исходных метрик.

```
conda env create -f environment.yml
conda activate sber
make test
make research-prophet # 1 worker; совместимый кэш используется повторно
make research
make verify
make report
```

Перед `research` нужны исходные данные и прогнозы `source_run`. Полное воспроизведение с нуля: `make all`, затем команды выше; оно существенно дороже лёгкого повторного анализа. Установка зависимостей в новой среде с нуля и независимая внешняя временная отметка пока не подтверждены. Просмотренный тест не используется для заявления нового независимого выигрыша.

Критерии и веса подтверждены пользователем 07.10.2026. Точный `baseline` и правила валидации ещё не предоставлены; подробной шкалы качества внутри критериев нет. Итоговое сопоставление — `docs/CRITERIA_AUDIT_RU.md`; баллы жюри и численный шанс на приз не оцениваются.

Влияние региональных новостей на прогнозы и детекторы

Пилот: Оренбургская область, 39 МО, 234 ряда, 24 месяца (2023–2024). Корпус — 28900 заголовков, 2 источника; публикации найдены в 24 из 24 месяцев. Запуск: `artifacts/regional_news_runs/news_20261007T171936_092637Z`. Расчёт занял 24.7 секунды, один вычислительный поток; обучение фундаментальных моделей не повторялось.

Вывод: Новостной вариант снижает MAE относительно `without_news` на горизонтах 1, 3, 12; повышает на 6. Сохранённый ансамбль точнее `with_news` на всех горизонтах. Результат исследовательский; детекторные сравнения чувствительны к финансовой проху-разметке.

source	Публикаций
ГУ МЧС России по Оренбургской области	53
Оренбург Медиа	28847

Протокол

Конфигурация — `configs/news_impact.json`. Обучение прогнозов: расширяющееся окно, метки только до `origin` включительно. Валидация — цели 01–06.2024, тест — 07–12.2024; горизонты 1/3/6/12. Ridge `alpha=1000`, `shrink=0.25` и ограничение коррекции $\pm 0.3 \log$ заданы одинаково для вариантов до запуска. Категории кодируются индикаторами; заполнение пропусков и масштабирование обучаются только на прошлых строках. Будущий горизонт не усиливает дрейф дальше максимального обученного горизонта.

Прогнозная база — национальный сезонный путь `NatPath_K3`; Ridge оценивает муниципальное отклонение. Сравниваются одинаковые модели: `without_news`, `coverage_only` (объём по источникам), `with_news` (все признаки), `delayed_news_3m` (задержка на 3 месяца), `mchs_only` (исходный корпус), `crisis_only` (ЧС из расширенного корпуса), `economic_only` (экономические темы). Последние два варианта сохраняют одинаковые признаки покрытия, изолируя темы. Задержанный контроль не использует будущие публикации раньше оригинала; он не является доказательством причинности.

Новостные признаки: $\log(1+\text{количество})$ за последние 1 и 3 календарных месяца, по источникам, десяти темам и известному МО. Четыре темы ЧС дополнены ценами, доходами/работой, выплатами, торговлей/услугами, предприятиями,

транспортом/жильём. Пять признаков направления: рост/снижение цен, рост доходов, открытие/закрытие бизнеса. Всего 58 признаков; имена — news_feature_schema.json. Правила фиксированы без подбора по тесту. Материалы с неподтверждённой географией не создают тематический сигнал. При известном МО событие не переносится на все МО области. Заголовок может иметь несколько тем; упоминание суммы не превращается в финансовый показатель.

Для детекторов используется сохранённый финансовый стандартизованный остаток z , рассчитанный по прошлой истории. Новостной вариант усиливает z в 1.5 раза только в месяц доступной тематической публикации соответствующей географии; нулевой финансовый остаток не превращается в тревогу. Пороги каждого варианта выбираются только на калибровке 11.2023–06.2024 при одном максимальном бюджете 1 тревога на 100 ряд-месяцев. Это бюджет общего количества тревог, а не доказанных ложных тревог. Реализованный бюджет может различаться из-за дискретной сетки. Тестовые частоты не обязаны соблюдать калибровочный бюджет.

Насыщение новостного входа

variant	mean_fraction_series_with_signal	months_same_as_coverage
coverage_only	1.000	6
crisis_only	1.000	6
delayed_news_3m	1.000	6
economic_only	1.000	6
mchs_only	0.004	0
with_news	1.000	6
without_news	0.000	0

При большом корпусе правило «есть хотя бы одна тематическая новость» может включаться во всех ряд-месяцах. Тогда новостной вариант лишь постоянно масштабирует финансовый остаток; изменение тревог объясняется масштабом и дискретной сеткой порогов. Совпадение с coverage_only означает, что дополнительная польза содержания новостей для детектора не показана. Следующий содержательный вариант должен проверять локальную интенсивность или новизну тем на новых данных; правило после просмотра теста здесь не подбиралось.

Прогнозы: основной контроль

Меньшая MAE лучше. Изменение положительное означает ухудшение.

Горизонт, мес	MAE без новостей	MAE с новостями	Изменение MAE, %
1.000	394.555	380.665	-3.520
3.000	573.485	545.454	-4.888
6.000	555.054	731.825	31.848
12.000	755.427	740.189	-2.017

Валидационные MAE:

model	1	3	6	12
NatPath_K3	358.540	524.403	739.684	677.480
coverage_only	367.454	436.039	836.198	677.480
crisis_only	340.679	429.548	744.357	677.480
delayed_news_3m	332.770	345.747	720.716	677.480
economic_only	349.545	401.819	748.919	677.480
mchs_only	340.036	349.436	801.735	677.480
with_news	347.913	407.696	753.600	677.480
without_news	348.193	336.700	764.989	677.480

Выбор между without_news и with_news по валидации допускает новости на h=1,6; при равенстве выбирает without_news. Это исследовательский выбор внутри пилота, а не новая глобальная модель проекта.

h	selected_on_validation	validation_mae_without_news	validation_mae_with_news	test_mae_selected
1	with_news	348.193	347.913	380.665
3	without_news	336.700	407.696	573.485
6	with_news	764.989	753.600	731.825
12	without_news	677.480	677.480	755.427

Bootstrap по шести целевым месяцам, delta=MAE варианта – MAE без новостей:

variant	h	delta_mae_vs_without_news	month_ci_low	month_ci_high	municipality_ci_low	municipality_ci_high	target_months
with_news	1	-13.890	-25.082	-2.758	-17.025	-10.550	6
with_news	3	-28.032	-85.514	24.344	-37.697	-18.987	6
with_news	6	176.771	-0.460	356.405	157.977	197.515	6
with_news	12	-15.238	-96.736	64.117	-28.701	-5.708	6

Месячный интервал разности news–coverage целиком ниже нуля на h=1. Сравнения множественные и исследовательские. Узкие интервалы по МО не устраняют зависимость от общих региональных месяцев; шестимесячный тест не подтверждает устойчивость эффекта.

h	delta_mae_news_vs_coverage_only	month_ci_low	month_ci_high
1.000	-12.466	-22.805	-2.325
3.000	-31.763	-99.907	27.439
6.000	116.572	9.876	253.543
12.000	84.490	22.628	165.432

Все новые варианты и сохранённые ориентиры на тех же рядах:

model	1	3	6	12
CachedEnsemble	367.332	425.870	424.662	511.778
CachedProphet	466.109	527.422	533.743	781.341
NatPath_K3	396.493	619.356	661.799	584.683
coverage_only	393.131	577.217	615.254	655.699
crisis_only	376.935	533.075	856.565	765.625
delayed_news_3m	375.862	559.070	601.959	797.093
economic_only	379.265	554.430	665.790	704.811
mchs_only	386.594	558.411	583.609	798.802
with_news	380.665	545.454	731.825	740.189
without_news	394.555	573.485	555.054	755.427

CachedEnsemble/CachedProphet — ранее сохранённые прогнозы, они не переобучались и не являются парной абляцией архитектуры Ridge. Их ретроспективные ограничения описаны в основном аудите. Сохранённый ансамбль точнее with_news на всех горизонтах.

Какие признаки использовала модель

feature	mean_abs_coefficient	mean_signed_coefficient
log_local_fire_3m	0.002	0.002
log_relevant_transport_housing_3m	0.002	-0.002
log_relevant_weather_1m	0.002	-0.002

feature	mean_abs_coefficient	mean_signed_coefficient
log_business_closure_1m	0.002	0.002
log_relevant_business_industry_3m	0.002	-0.002
log_local_infrastructure_3m	0.002	0.002
log_relevant_flood_or_evacuation_1m	0.002	0.001
log_local_retail_services_3m	0.002	0.002
log_relevant_payments_support_1m	0.002	-0.001
log_relevant_fire_3m	0.002	-0.002
log_local_payments_support_3m	0.002	0.002
log_relevant_business_industry_1m	0.002	0.002

Средние коэффициенты Ridge после стандартизации на $origin \leq 17$, до тестового периода. Это диагностика модели, не причинный эффект: темы коррелируют между собой и со временем.

Детекторы

Независимая от новостей ориентировочная разметка: DP-сегментация финансового z, минимальная длина сегмента 4, минимальный сдвиг 1.5σ. Проверены штрафы $2/4/8 \cdot \log(T)$. Сами эти метки используют весь ряд и не являются доказанными реальными шоками. Новости не используются для формирования эталона. Совпадения считаются один-к-одному, задержка до 3 месяцев, только события и тревоги тестового периода.

Основной срез штрафа 4:

method	variant	n_proxy_events	n_alarms	matched_proxy_events	proxy_precision	proxy_recall	proxy_f1	median_delay_months
CUSUM	without_news	14	19	0	0.000	0.000	0.000	nan
PageHinkley	without_news	14	47	1	0.021	0.071	0.033	1.000
BOCPD	without_news	14	5	2	0.400	0.143	0.211	1.000
CUSUM	with_news	14	13	1	0.077	0.071	0.074	2.000
PageHinkley	with_news	14	57	3	0.053	0.214	0.085	2.000
BOCPD	with_news	14	19	4	0.211	0.286	0.242	1.500

Уменьшение числа тревог само по себе не доказывает рост качества. Оценивать нужно precision, recall и чувствительность к варианту разметки совместно.

Чувствительность F1 к штрафу разметки:

method	proxy_penalty	n_proxy_events	with_news	without_news
BOCPD	2	32	0.314	0.162
BOCPD	4	14	0.242	0.211
BOCPD	8	3	0.182	0.500
CUSUM	2	32	0.044	0.000
CUSUM	4	14	0.074	0.000
CUSUM	8	3	0.000	0.000
PageHinkley	2	32	0.135	0.101
PageHinkley	4	14	0.085	0.033
PageHinkley	8	3	0.067	0.040

Полная таблица всех тематических контролей и методов сохранена в detector_metrics.csv. Универсального победителя по одному выбранному штрафу не устанавливаем.

Выбранные пороги и фактические частоты:

variant	method	threshold	calibration_alarm_rate_per_100	test_alarm_rate_per_100	test_alarms
without_news	CUSUM	12.000	0.588	1.353	19
without_news	PageHinkley	12.000	0.214	3.348	47
without_news	BOCPD	0.700	0.160	0.356	5
coverage_only	CUSUM	24.000	0.214	0.926	13
coverage_only	PageHinkley	16.000	0.641	4.060	57
coverage_only	BOCPD	0.700	0.801	1.353	19
with_news	CUSUM	24.000	0.214	0.926	13
with_news	PageHinkley	16.000	0.641	4.060	57
with_news	BOCPD	0.700	0.801	1.353	19
delayed_news_3m	CUSUM	24.000	0.214	0.926	13
delayed_news_3m	PageHinkley	16.000	0.641	4.060	57
delayed_news_3m	BOCPD	0.700	0.801	1.353	19
mchs_only	CUSUM	16.000	0.321	0.427	6
mchs_only	PageHinkley	12.000	0.481	3.276	46
mchs_only	BOCPD	0.700	0.267	0.285	4
crisis_only	CUSUM	24.000	0.214	0.926	13
crisis_only	PageHinkley	16.000	0.641	4.060	57
crisis_only	BOCPD	0.700	0.801	1.353	19
economic_only	CUSUM	24.000	0.214	0.926	13
economic_only	PageHinkley	16.000	0.641	4.060	57
economic_only	BOCPD	0.700	0.801	1.353	19

Изменившиеся тревоги могут появляться и позже месяца новости из-за состояния детектора, cooldown и нового порога. Их нельзя все объяснять конкретным событием. Ниже два локальных примера изменившихся тестовых тревог, не доказательство правильного обнаружения:

method	territory_id	mo_name	category	month_index	month	baseline_alarm	news_alarm	news_signal
BOCPD	1665	Оренбург	Общественное питание	20	2024-09-01	False	True	1.000
BOCPD	1668	Бузулук	Общественное питание	21	2024-10-01	False	True	1.000

Ограничения и решение

- Регион и тест уже рассматривались ранее; результат исследовательский, не независимая финальная оценка. Региональная выборка не обосновывает улучшение по всей России.
- МЧС — неполная поисковая выборка; Оренбург Медиа — датированный архив JSON, охватывающий также экономику и общество. Полнота страниц проверяется по X-WP-TotalPages в news_orenburg_archive_audit.csv; это не полнота всех новостей региона. Ноль найденных публикаций не означает отсутствие событий.
- API возвращает текущие версии заголовков; дата публикации берётся из date_gmt, история исправлений неизвестна. Региональные СМИ могут перепечатывать федеральные новости: тематические признаки требуют явной географии.
- Историческая доступность принимается по дате публикации. Фактический first_seen_at — 2026 год; в строгом онлайн-режиме эти сообщения не были получены системой в 2023–2024.
- Годовые версии географии не позволяют установить точный месяц административного изменения. Финансовые проху-метки требуют экспертной проверки.
- Для h=12 валидация содержит один целевой месяц; доступные новости относятся к ранним origin, а не к будущему паводку. Будущие сообщения не подставлялись.

Практическое решение: основной ансамбль и выбранный основной детектор сохраняются. Новостной корпус расширен экономическим источником; следующий шаг — новые неиспользованные целевые месяцы, независимый источник экономики и экспертная проверка географии/тем.

Воспроизведение и проверка

```
python scripts/collect_news_archive.py --offline # повторная обработка кеша без сети
OMP_NUM_THREADS=1 OPENBLAS_NUM_THREADS=1 nice -n 15 python scripts/evaluate_news_impact.py
OMP_NUM_THREADS=1 OPENBLAS_NUM_THREADS=1 nice -n 15 python scripts/build_news_impact_report.py
```

Нужны локальный CSV новостей, муниципальные входы и сохранённые z/прогнозы из исходного запуска. Хеши всех входов и кода сохранены в manifest.json, конфигурация — в config.json. forecast_predictions.csv содержит прогнозы теста, detector_alarms.csv — тревоги, detector_proxy_labels.csv — независимые от новостей ориентиры, detector_changed_alarms.csv — изменившиеся тревоги. Предыдущие запуски не перезаписываются.

Проверки текущего запуска: 7/7 выполнено; метки обучения не позже origin, новости до cutoff, калибровочные частоты в бюджете, полное покрытие прогнозов и совпадение хешей. Первый технический запуск помечен superseded_invalid_geography_numeric_csv_cast: исправлена интерпретация числовых territory_id из CSV; его результаты не используются.